数问 DataPilot

让数据，回答问题。

AI WEB 网页开发挑战赛 • AI 数据分析与可视化方向

从一份 CSV 到一次可核验的探索：自然语言生成分析计划，确定性引擎计算统计结果，图表与报告提供来源和口径。

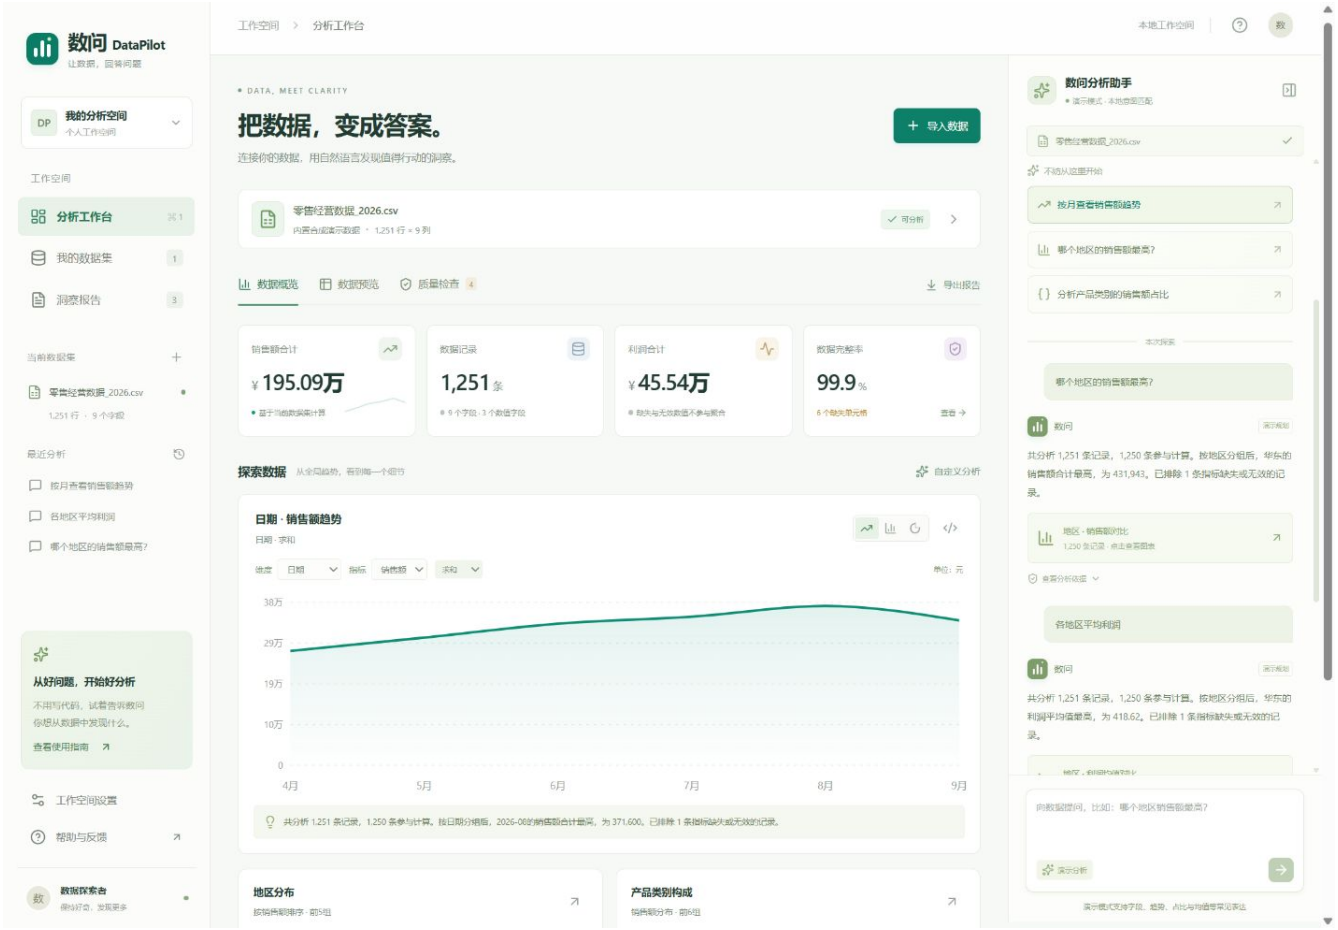


图 1：桌面工作台实际运行界面。截图明确标示演示模式，统计数字来自合成样本实际计算。

交付范围

已实现上传、质量检查、联动筛选、来源回溯、异常侦探、情景推演、洞察收藏对比与连续追问。尚需配置真实模型密钥并实测，录制视频并准备评审访问。

1. 项目概述

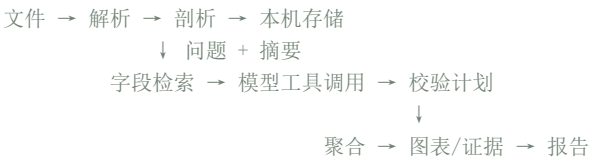
数问面向需要做课程实验、探索业务表格的大数据学生与初级分析者，提供“导入数据、自然语言提问、图表探索、核对口径、导出报告”的工作流程，对应 AI 数据分析与可视化方向。

常见问题包括制作图表耗时、模型口头结论难以核验、样例无法替换为自己的数据。数问将语言理解与计算分开，每个结果可核对字段、聚合方式和参与记录。项目边界为单表探索性统计，不承诺自动发现因果或未计算的预测。

2. 系统架构

前端为 React 与 TypeScript，桌面三栏工作台，手机使用助手抽屉。图表采用 Recharts，图标采用 Lucide，定制 CSS 实现视觉与响应式。Vinext/Vite 与 Cloudflare Workers 提供同源路由，保留 Sites 托管访问控制。

文件在浏览器完成解析、剖析、清洗与聚合，存入 IndexedDB。服务端只接收问题与字段摘要，在有密钥时调用模型。服务端使用 Zod 与真实字段约束验证计划，浏览器执行前再次检查。



3. 数据处理

支持 CSV / TSV、UTF-8 BOM 和常见中文编码回退。兼容双引号、引号转义、字段内逗号与换行；拒绝列数不一致、重名字段、危险对象字段与超限文件。限制为 5 MB、20,000 行、80 列。

推断数值、日期与文本类型。缺失保持 null，数值聚合排除缺失和无效值，均值以有效记录为分母。纯日期保留日历日期，避免时区令月初记录落入前月。完全重复记录默认保留，由用户主动清洗。

质量评分为完整率减去 20 倍重复记录占比，是辅助指标而非通用质量标准。清洗支持去重、首尾空白处理和缺失标记，不擅自用 0 填充。清洗会清空旧分析、筛选和收藏，撤销同时恢复它们。

4. AI 方案

字段检索根据问题中的字段名、分类值和时间意图排序，最多选 24 个字段进入上下文。当前为关键词检索，不是向量数据库 RAG。数值和日期高频原值不发送；常见敏感字段的分类值过滤，但仍不能代替正式脱敏。

模型必须调用 create_analysis_plan，输出维度、指标、sum/mean/count/min/max、日/月分桶、排序、展示条数、可选筛选条件和图表类型。Zod 检查结构，真实字段白名单检查指标和筛选。不存在的字段、不合法聚合和越界条数被拒绝。

模型不输出最终统计数字。浏览器执行确定性计划，再从真实结果生成说明，包含匹配数、有效数、排除数和极值；图表与报告复用同一结果。SQL 面板是口径示意，不执行任意 SQL 或模型代码。

连续追问发送 previousPlan，允许在原有指标与范围上修改聚合或维度。模型仍受相同结构与字段约束；演示模式仅在“改成、再按、只看”等有限表达中继承上下文。最多 8 项筛选按 AND 合并，同字段同操作符以新值替换旧值。

无密钥时明确显示演示模式，使用有限意图规则。未支持的预测、因果等任务返回提示，不假装完成。配置支持工具调用的服务后使用真实模型；本轮未提供密钥，真实服务调用未实测，仅完成模拟协议与错误验证。

5. 前端与交互

概览卡片及图表来自当前数据，可切换维度、指标、聚合和图表。表格支持搜索分页，质量页面查看各字段缺失与异常。助手通过 SSE 展示规划状态，支持取消与错误恢复，并可展开计算依据。

最近 30 次分析与文件保存于当前浏览器；报告包含来源、统计、聚合表、口径和限制。提供键盘焦点、可访问标签、模态框焦点约束及减少动画偏好支持。

5.1 联动探索与来源回溯

联动筛选同步更新 KPI、主图、分组图、构成图与预览，质量检查保持原始范围。图表点击或键盘可用的分组按钮打开来源明细，包含被排除的缺失指标记录，支持搜索、分页、CSV 导出和反向筛选。时间来源复用相同的日期分桶逻辑。

5.2 异常侦探与情景推演

异常检测使用线性插值四分位数，IQR=Q3-Q1，边界为 Q1-k×IQR 与 Q3+k×IQR；k 可在 0.5-3.0 调整。展示有效数、缺失数、中位数和边界，少于 4 条有效记录不判定。异常只作线索，不自动删除。

情景推演在当前筛选范围内，对全部或某一分类的单项数值指标做比例调整，显示原始与模拟合计、变化量、影响记录及对照图。模拟合计=基线合计+目标记录指标合计×调整率。创建数据副本，不改原表，不预测未来、不推断因果。

5.3 洞察收藏与同口径对比

最多保存 12 项配置，支持改名、批注、搜索、恢复、导出及删除撤销。结果从原数据重算；对比前要求维度、指标、聚合和时间粒度一致，无匹配分组保留 null，显示不可比，不冒充 0。比较范围限于各自展示的 Top N 分组。

6. 安全与复现

密钥只在服务端配置，不下发浏览器。请求大小、问题长度、字段数和计划枚举受限；模型生成代码从不执行。文本由 React 转义；CSV 导出防护公式注入，同时保留合法负数。

模型仍会收到字段摘要与部分分类值，不将方案描述为零泄露。用户需有权使用数据。默认零售数据为固定随机种子生成的合成样本，含 1,251 行、6 个缺失和 3 条重复，可重复生成与核对。

保留依赖锁、环境变量模板、测试脚本与真实提交；不事后伪造开发历史。私人站点保持所有者访问，赛事评审可访问性须另行准备。

7. 测试与部署

22 项核心测试覆盖解析边界、缺失排除、重复保留、日期分桶、聚合筛选、非法字段拒绝、清洗不变性、导出防护、报告、演示标识、模型协议与失败路径。新增 15 项测试覆盖 AND 筛选、来源、异常、模拟不变性、同口径比较、连续追问与模型上下文。另提供 HTTP 状态、错误请求、大小限制、SSE 与非法上下文测试。

已在浏览器验证提问生成真实计算、数据搜索、去重和撤销。类型检查与生产构建使用实际安装依赖运行。真实模型效果需密钥与额度后验证；下载内容测试不等同于浏览器下载已落盘。

新增 8 行可手算样本：销售额合计 4910，IQR 上界 205，异常为 4000；仅将华东销售额提高 10% 时总模拟值 4960。浏览器核对结果与计算测试一致，并验证收藏批注、移除撤销、连续追问和 390 像素手机布局。

部署为 Worker 与前端资源，使用平台源码、构建归档与版本发布机制。本站默认私人访问。

8. 评分对应与改进

维度	当前实现依据	待加强
AI 深度	工具调用、字段检索、计划验证、上下文追问、确定性执行	真实模型评估、向量检索、多模态、MCP
创新性	来源联动、可解释异常、情景对照、收藏口径复现	用户访谈与对照实验
前端工程	类型、模块、取消、边界和核心测试	大文件 Web Worker、持续集成
实用性	上传到导出闭环、范围筛选、洞察对比	多表、Excel、复杂统计
用户体验	响应式工作台、来源回溯、可撤销操作	更多无障碍实测
社会与商业价值	降低入门门槛、培养数据核验习惯	尚无商业或用户增长验证

后续优先接入真实模型，建立固定问题集，记录字段选择正确率、计划有效率、数值一致性、延迟与成本；再补真实需求证据、视频和评审访问配置。不能在没有实测时填写准确率、性能或用户量。

赛道规则：https://www.boxuegu.com/matchTrack/detail/?id=10037

附录：创新实验室运行界面

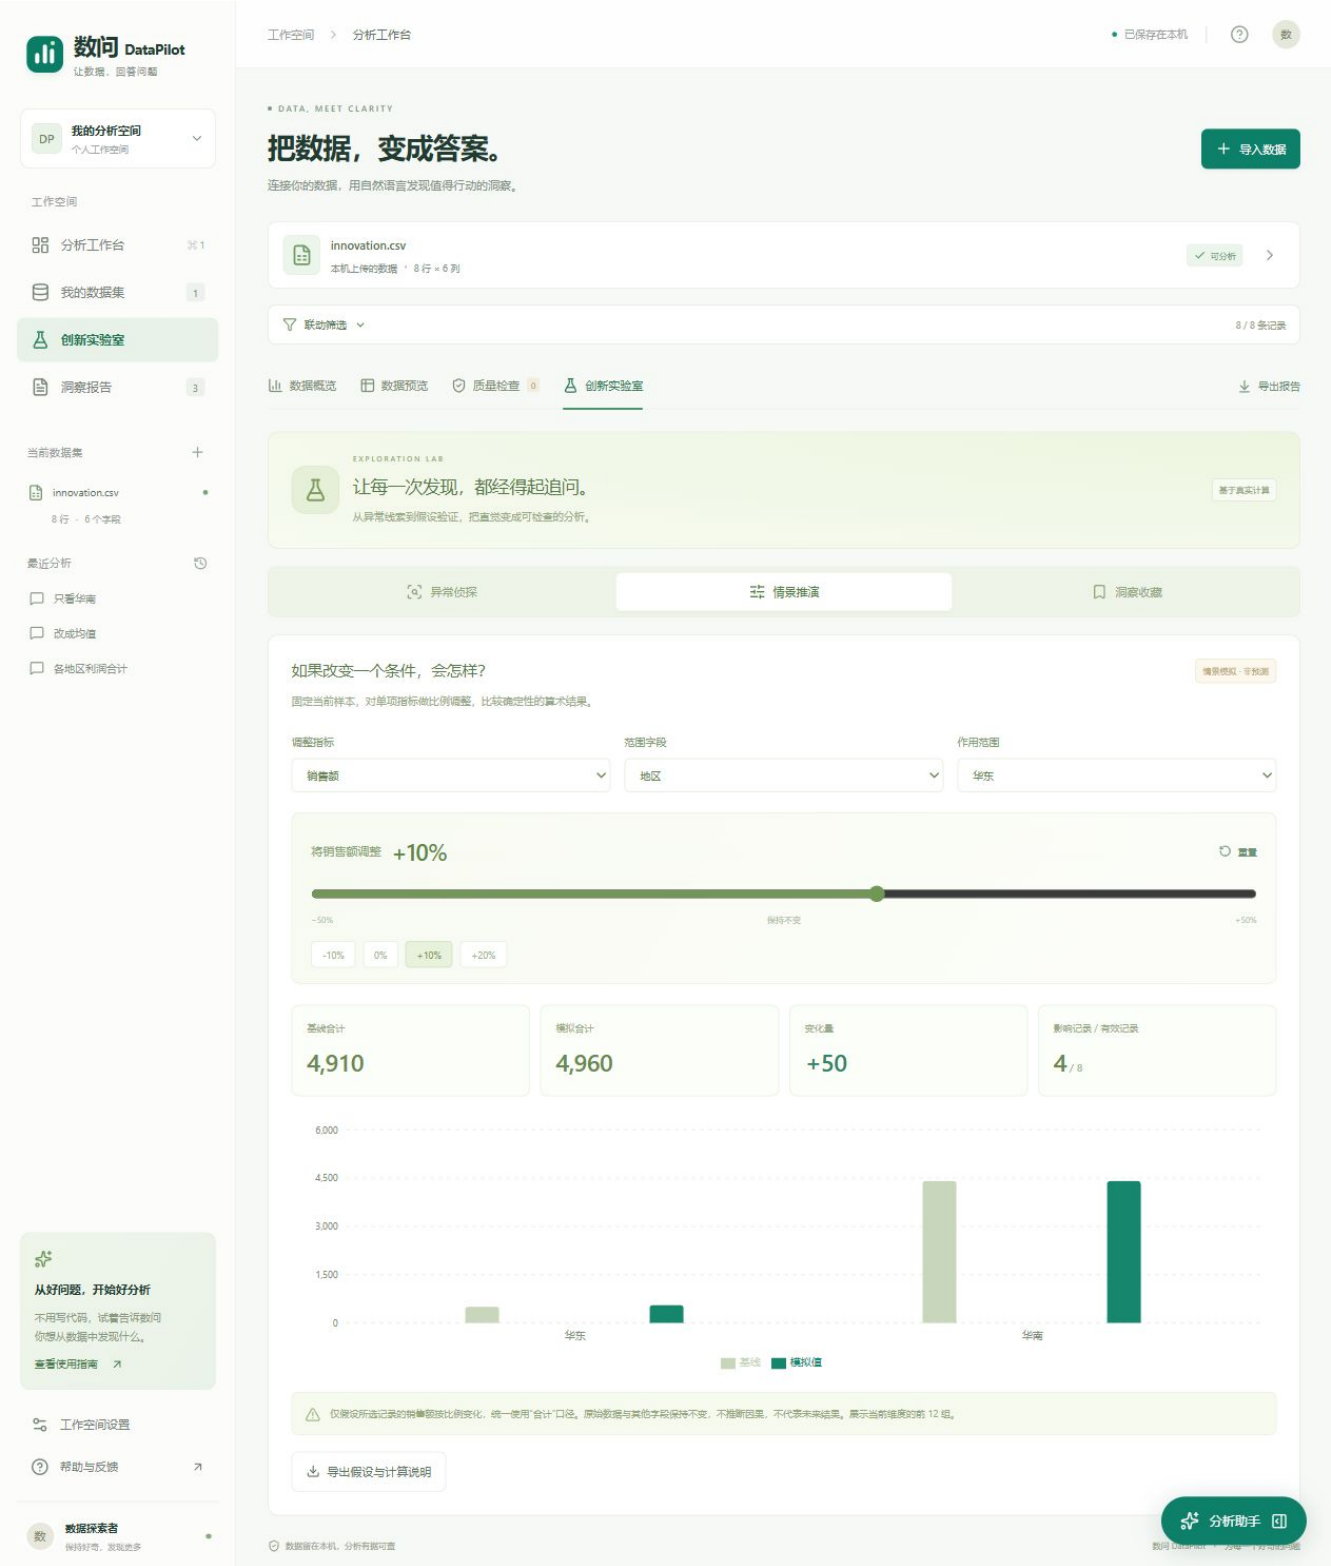


图 2：8 行合成样本，仅将华东销售额增加 10%，总模拟值 4960；该界面为固定样本的情景模拟，不是预测。