数问 DataPilot

让数据，回答问题。

AI WEB 网页开发挑战赛 • AI 数据分析与可视化方向

从一份 CSV 到一次可核验的探索：自然语言生成分析计划，确定性引擎计算统计结果，图表与报告提供来源和口径。

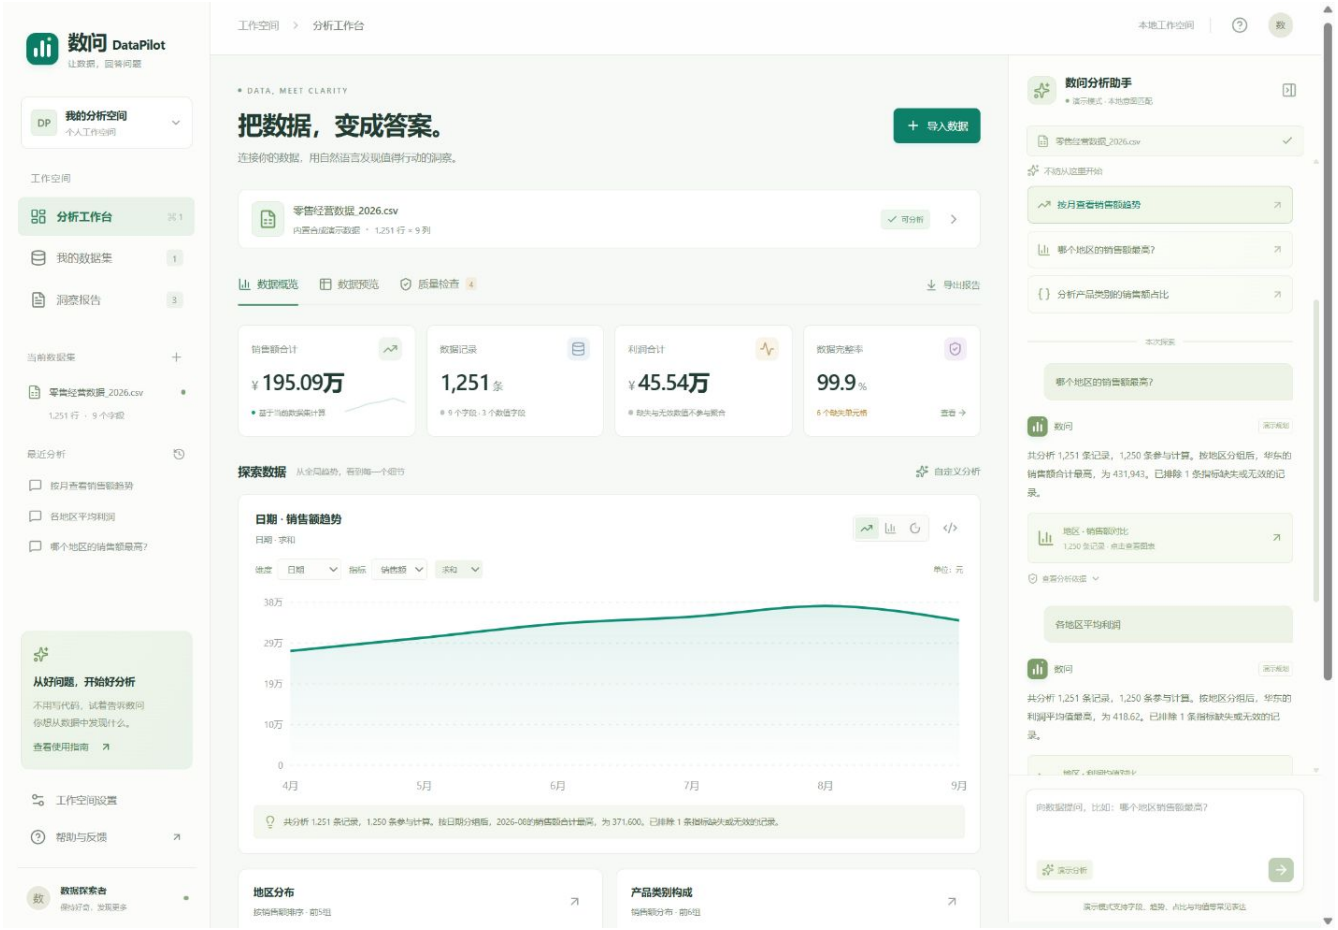


图 1：桌面工作台实际运行界面。截图明确标示演示模式，统计数字来自合成样本实际计算。

交付范围

上传、质量检查、联动与下钻、异常、情景推演、收藏对比、字典、连续追问、配置迁移和离线报告。已建立GitHub公开评审仓库，正式提交仍需团队信息、真实模型实测和MP4。

1. 项目概述

数问面向需要做课程实验、探索业务表格的大数据学生与初级分析者，提供“导入数据、自然语言提问、图表探索、核对口径、导出报告”的工作流程，对应 AI 数据分析与可视化方向。

常见问题包括制作图表耗时、模型口头结论难以核验、样例无法替换为自己的数据。数问将语言理解与计算分开，每个结果可核对字段、聚合方式和参与记录。项目边界为单表探索性统计，不承诺自动发现因果或未计算的预测。

1.1 需求分析

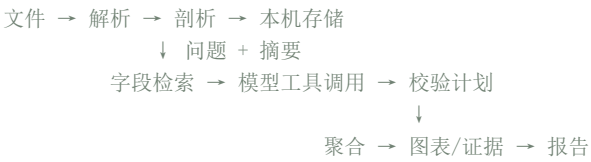
目标场景为大数据本科生的课程实验、社团表格统计和小规模 CSV 探索。学生需要降低表达和制图门槛；教师或协作者需要复核样本范围、业务口径与计算结果。当前问题定义来自使用场景分析，尚未完成访谈或用户研究，不填写虚构需求验证。

核心需求为：用户可替换自己的文件；问题映射到真实字段；关键统计可查看来源；相同数据和配置可复现；导出的成果可离线核对。验收以固定合成样本、可手算结果、独立边界测试和浏览器交互为依据。商业推广、真实企业效益与用户增长不作为已实现成果。

2. 系统架构

前端为 React 与 TypeScript，桌面三栏工作台，手机使用助手抽屉。图表采用 Recharts，图标采用 Lucide，定制 CSS 实现视觉与响应式。Vinext/Vite 与 Cloudflare Workers 提供同源路由，保留 Sites 托管访问控制。

文件在浏览器完成解析、剖析、清洗与聚合，存入 IndexedDB。服务端只接收问题与字段摘要，在有密钥时调用模型。服务端使用 Zod 与真实字段约束验证计划，浏览器执行前再次检查。



3. 数据处理

支持 CSV / TSV、UTF-8 BOM 和常见中文编码回退。兼容双引号、引号转义、字段内逗号与换行；拒绝列数不一致、重名字段、危险对象字段与超限文件。限制为 5 MB、20,000 行、80 列。

推断数值、日期与文本类型。缺失保持 null，数值聚合排除缺失和无效值，均值以有效记录为分母。纯日期保留日历日期，避免时区令月初记录落入前月。完全重复记录默认保留，由用户主动清洗。

质量评分为完整率减去 20 倍重复记录占比，是辅助指标而非通用质量标准。清洗支持去重、首尾空白处理和缺失标记，不擅自用 0 填充。清洗会清空旧分析、筛选和收藏，撤销同时恢复它们。

4. AI 方案

字段检索根据问题中的字段名、分类值和时间意图排序，最多选 24 个字段进入上下文。当前为关键词检索，不是向量数据库 RAG。数值和日期高频原值不发送；常见敏感字段的分类值过滤，但仍不能代替正式脱敏。

4.1 选型理由与优化策略

使用可配置的 Chat Completions Function Calling 服务，将语言理解限定为结构化计划，避免执行模型任意代码；服务商、模型和密钥均由环境变量配置，默认值不代表已经接通。前端采用 React/TypeScript 保持组件化，Recharts 负责图表，Zod 负责跨边界结构校验。本项目自行实现业务计算，而非包装已有数据分析平台。

提示词把用户问题、数据摘要与业务定义视为不可信输入，要求调用固定工具，不生成统计数字。输入限制为 2000 字问题、80 个原字段、最多 24 个检索字段；上下文优先保留上一轮维度、指标与筛选字段。模型超时 45 秒，限制输出长度并校验字段、枚举和 Top N，提供明确的错误状态。限量摘要减少上下文开销，但尚无真实延迟或成本评测结果。

字段字典提供长度受限的释义、单位和最多 8 个别名；冲突别名被拒绝，别名只映射到原字段，不创造公式。定义同时用于本地演示匹配和真实模型上下文，单位只是显示标签，不自动换算数值。

模型必须调用 create_analysis_plan，输出维度、指标、sum/mean/count/min/max、日/月分桶、排序、展示条数、可选筛选条件和图表类型。Zod 检查结构，真实字段白名单检查指标和筛选。不存在的字段、不合法聚合和越界条数被拒绝。

模型不输出最终统计数字。浏览器执行确定性计划，再从真实结果生成说明，包含匹配数、有效数、排除数和极值；图表与报告复用同一结果。SQL 面板是口径示意，不执行任意 SQL 或模型代码。

连续追问发送 previousPlan，允许在原有指标与范围上修改聚合或维度。模型仍受相同结构与字段约束；演示模式仅在“改成、再按、只看”等有限表达中继承上下文。最多 8 项筛选按 AND 合并，同字段同操作符以新值替换旧值。

无密钥时明确显示演示模式，使用有限意图规则。未支持的预测、因果等任务返回提示，不假装完成。配置支持工具调用的服务后使用真实模型；本轮未提供密钥，真实服务调用未实测，仅完成模拟协议与错误验证。

5. 前端与交互

概览卡片及图表来自当前数据，可切换维度、指标、聚合和图表。表格支持搜索分页，质量页面查看各字段缺失与异常。助手通过 SSE 展示规划状态，支持取消与错误恢复，并可展开计算依据。

最近 30 次分析与文件保存于当前浏览器；报告包含来源、统计、聚合表、口径和限制。提供键盘焦点、可访问标签、模态框焦点约束及减少动画偏好支持。

5.1 联动探索与来源回溯

联动筛选同步更新 KPI、主图、分组图、构成图与预览，质量检查保持原始范围。图表点击或键盘可用的分组按钮打开来源明细，包含被排除的缺失指标记录，支持搜索、分页、CSV 导出和反向筛选。时间来源复用相同的日期分桶逻辑。

5.2 异常侦探与情景推演

异常检测使用线性插值四分位数，IQR=Q3-Q1，边界为 Q1-k×IQR 与 Q3+k×IQR；k 可在 0.5-3.0 调整。展示有效数、缺失数、中位数和边界，少于 4 条有效记录不判定。异常只作线索，不自动删除。

情景推演在当前筛选范围内，对全部或某一分类的单项数值指标做比例调整，显示原始与模拟合计、变化量、影响记录及对照图。模拟合计=基线合计+目标记录指标合计×调整率。创建数据副本，不改原表，不预测未来、不推断因果。

5.3 洞察收藏与同口径对比

最多保存 12 项配置，支持改名、批注、搜索、恢复、导出及删除撤销。结果从原数据重算；对比前要求维度、指标、聚合和时间粒度一致，无匹配分组保留 null，显示不可比，不冒充 0。比较范围限于各自展示的 Top N 分组。

5.4 下钻、成果报告与配置复现

来源明细可在保留当前分组的情况下继续按其他分类或日期字段分析；原指标和聚合方式保持，原历史不覆盖。离线 HTML 报告提供预览、SVG 条形图、完整聚合表、筛选范围、匹配/有效/排除数、字段字典和计算口径，支持浏览器打印。所有输入转义，CSP 禁止外部请求与脚本。

分析配置导出当前计划、收藏和字典，不含原始行，但会包含分类筛选值和批注。SHA-256 指纹绑定字段顺序及所有单元格内容，换了数据、行顺序或值即拒绝恢复；完整校验成功后才替换配置，原始数据和历史保持。该机制用于复现和防误用，不证明业务口径本身正确。

6. 安全与复现

密钥只在服务端配置，不下发浏览器。请求大小、问题长度、字段数和计划枚举受限；模型生成代码从不执行。文本由 React 转义；CSV 导出防护公式注入，同时保留合法负数。

模型仍会收到字段摘要与部分分类值，不将方案描述为零泄露。用户需有权使用数据。默认零售数据为固定随机种子生成的合成样本，含 1,251 行、6 个缺失和 3 条重复，可重复生成与核对。

保留依赖锁、环境变量模板、测试脚本与真实提交；不事后伪造开发历史。私人站点保持所有者访问，赛事评审可访问性须另行准备。

7. 测试与部署

22 项核心、15 项探索和 12 项字典/配置/报告测试，共 49 项；覆盖解析、缺失、日期、筛选、清洗、导出、防注入、模型协议、异常、模拟、同口径比较、连续追问、业务别名、上下文保留、下钻与同数据复现。另提供 HTTP 状态、错误请求、大小限制、SSE 与非法上下文测试。

已在浏览器验证提问生成真实计算、数据搜索、去重和撤销。类型检查与生产构建使用实际安装依赖运行。真实模型效果需密钥与额度后验证；下载内容测试不等同于浏览器下载已落盘。

新增 8 行可手算样本：销售额合计 4910，IQR 上界 205，异常为 4000；仅将华东销售额提高 10% 时总模拟值 4960。浏览器核对结果与计算测试一致，并验证收藏批注、移除撤销、连续追问和 390 像素手机布局。

真实模型评测脚本提供 6 道固定题、独立期望数值、计划与结果核对、耗时记录和源码指纹；未配置密钥时明确 blocked，不以模拟响应顶替。此脚本已经准备，真实调用仍未实测，不能据此报告模型准确率。

部署为 Worker 与前端资源，使用平台源码、构建归档与版本发布机制。本站默认私人访问。

8. 评分对应与改进

维度	当前实现依据	待加强
AI 深度	工具调用、字段检索、计划验证、上下文追问、确定性执行	真实模型评估、向量检索、多模态、MCP
创新性	来源联动、可解释异常、情景对照、收藏口径复现	用户访谈与对照实验
前端工程	类型、模块、取消、边界和核心测试	大文件 Web Worker、持续集成
实用性	上传到导出闭环、范围筛选、洞察对比	多表、Excel、复杂统计
用户体验	响应式工作台、来源回溯、可撤销操作	更多无障碍实测
社会与商业价值	降低入门门槛、培养数据核验习惯	尚无商业或用户增长验证

后续优先接入真实模型，建立固定问题集，记录字段选择正确率、计划有效率、数值一致性、延迟与成本；再补真实需求证据、视频和评审访问配置。不能在没有实测时填写准确率、性能或用户量。

8.1 技术与应用创新及市场差异

技术层面重点为受限规划与确定性计算分离、连续计划上下文、字段释义与别名、原始来源联动、同数据指纹复现。应用层面将异常核对、条件模拟、收藏比较和离线报告组织成适合课程实验的探索过程。功能思路可与市场产品相似，不能单凭通用能力宣称独占创新。

公开资料调研参考 Hex 的语义上下文、Metabase 的逐层下钻、Julius 的分析报告流程，独立实现上述能力，不复制其源码与品牌素材。详细来源及差异见项目竞品调研文档。下一步优先完成真实模型和用户验证，再考虑多表、复杂统计和长期可用性。

8.2 提交完整性结论

公开评审仓库为 https://github.com/233-arch/datapilot-chuanzhibei，保留完整真实历史。匿名API和Git核对默认分支、最终提交与必要材料；仓库检查结果须绑定当前提交。GitHub Actions另行运行类型、测试、源码扫描和构建，实际结果以远程记录为准。

当前仍缺学校与队员信息、实际普通话 MP4 和真实模型实测；在线演示为可选项，当前私人站点不能视为已开放评审。已提供七分钟录制路线、评测脚本、提交检查及 Git 历史迁移方案。自动检查不是官方认证，正式提交需参赛者核对报名、缴费和材料。

赛道规则：https://www.boxuegu.com/matchTrack/detail/?id=10037

附录：创新实验室运行界面

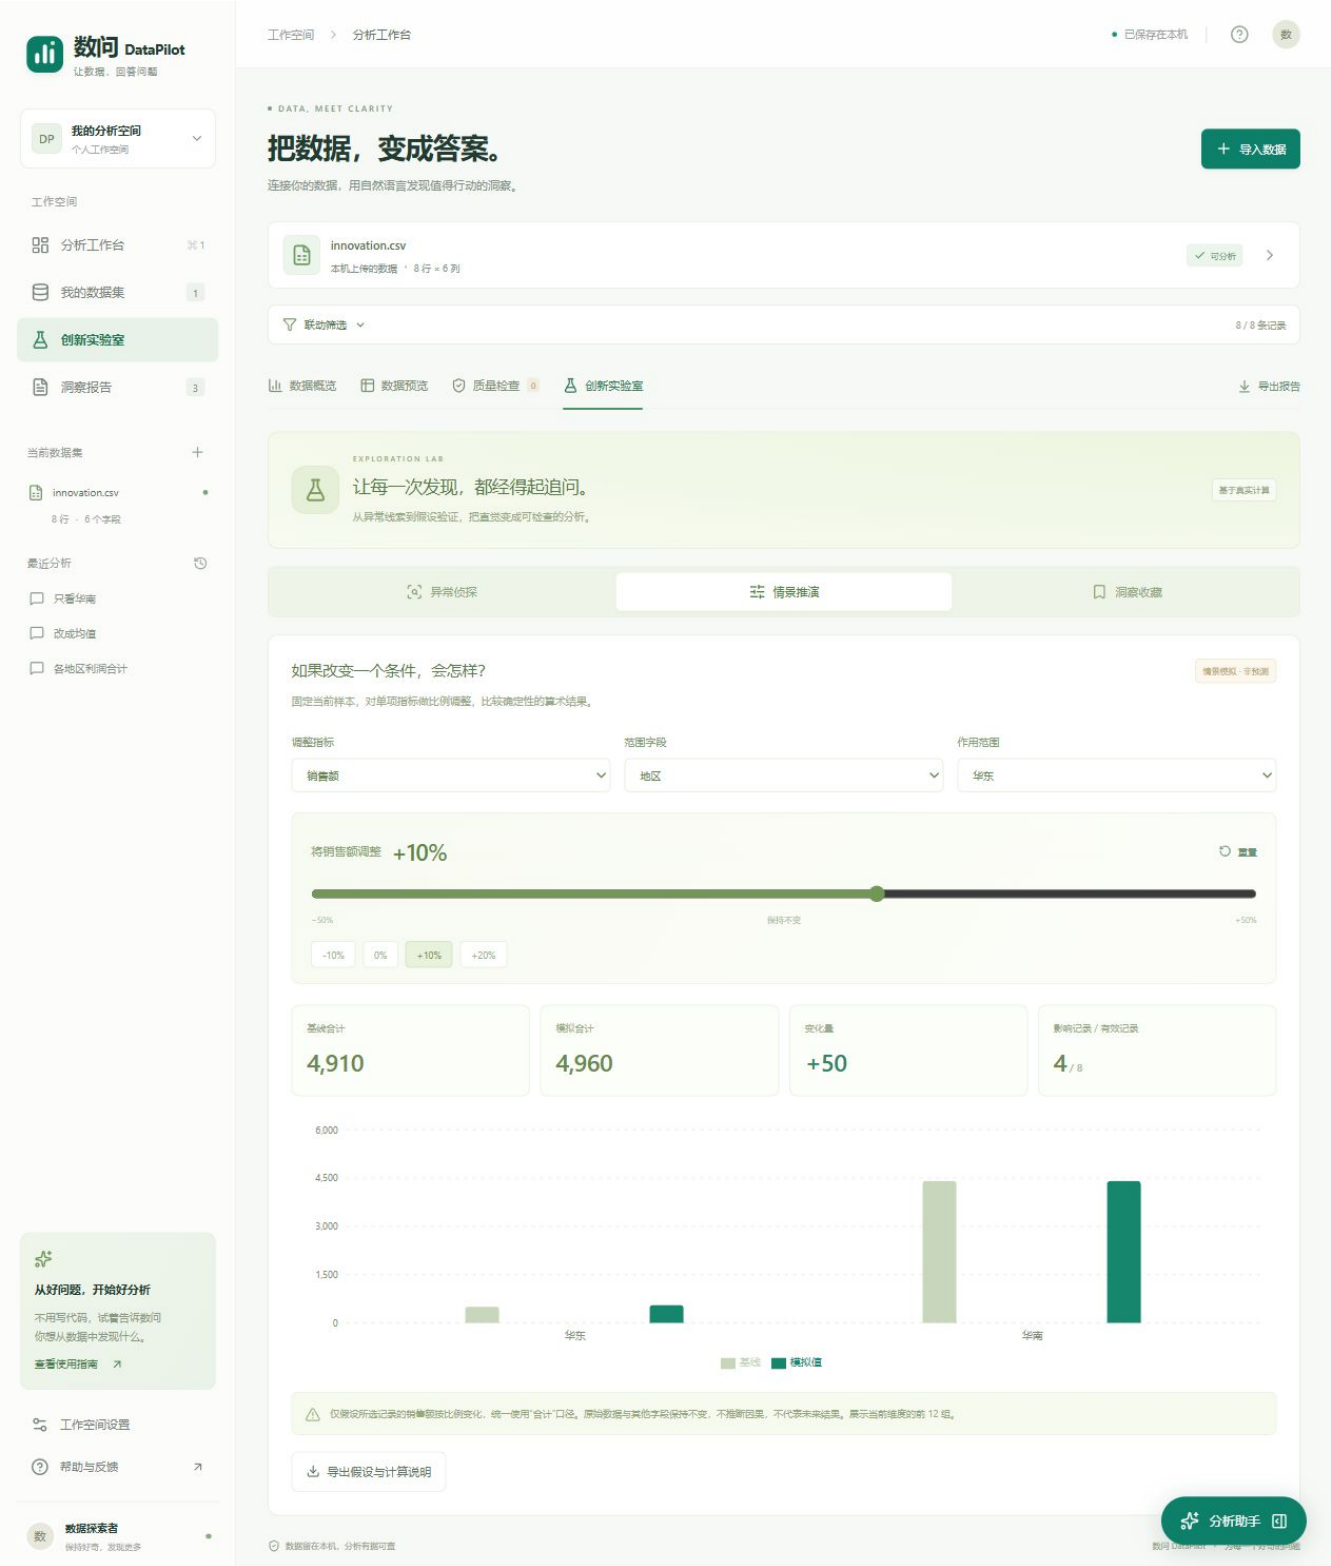


图 2：8 行合成样本，仅将华东销售额增加 10%，总模拟值 4960；该界面为固定样本的情景模拟，不是预测。